

İleri Düzey Teknikler ve Uygulamalar

Bu bölümde fine-tuning'in RAG'le farkına, reaktif bir sistemin nasıl otonom bir ajana dönüştüğüne ve prompt ile context mühendisliğinin birbirinden nasıl ayrıldığına baktım.

İnce Ayar (Fine-tuning)

Fine-tuning'i araştırınca şunu anladım: aslında eğitilmiş bir modeli alıp belirli bir konuda yeniden eğitmek. İyi tarafı, modelin davranışını/üslubunu kalıcı olarak değiştiriyor, her seferinde uzun bir talimat yazmana gerek kalmıyor. Kötü tarafı ise etiketli veri hazırlamak, eğitim maliyeti, ve modelin eski bilgiyi "unutma" riski (catastrophic forgetting).

RAG ise bilgiyi modelin dışında, bir vektör veritabanında tutuyor, her sorguda taze bilgi çekiyor — güncellemesi bir dosya değiştirmek kadar kolay ve kaynak da gösterebiliyor. Kendi çıkardığım kural şu oldu: **bilgi sık değişiyorsa ya da kaynak göstermek gerekiyorsa RAG; davranış/stil/format tutarlılığı önemliyse fine-tuning**. Zaten ikisi genelde birlikte de kullanılıyormuş.

Yapay Zekâ Ajanları (AI Agents)

Reaktif bir sistem, sadece soru sorulunca cevap veriyor, araç kullanmıyor, bir planı yok. Otonom bir ajan ise kendisine verilen bir hedefi kendi kendine adımlara bölüyor, hangi aracı (web araması, kod çalıştırma, veritabanı sorgusu) ne zaman kullanacağına kendisi karar veriyor, ara sonuca bakıp planını bile değiştirebiliyor. Reaktiften otonoma geçmek için teknik olarak neye ihtiyaç var diye baktım: araç çağırma (tool calling) desteği, ara sonucu tekrar modele geri besleyen bir döngü (buna *Reason → Act → Observe* deniyor), ve bir "ne zaman dur" kriteri.

İstem (Prompt) ve Bağlam (Context) Mühendisliği

Bu ikisini önce aynı şey sanmıştım. **Prompt Engineering**, modelin tek bir istekte doğru cevap vermesi için istem metnini (talimat, örnekler, format) düzenlemek —

yani "ne yazıyorum" sorusu. **Context Engineering** ise modelin sınırlı girdi kapasitesine (context window) nelerin, hangi sırayla, ne kadar yer kaplayarak konacağını yönetmek — RAG sonuçları, geçmiş konuşma, araç çıktıları arasında bir öncelik kararı. Sistem büyüdükçe (agent/RAG projelerinde) ikincisinin çok daha belirleyici olduğunu fark ettim.

FARK ETTİĞİM Bu ikisi rakip değil, birbirini tamamlıyor — iyi bir prompt bile yanlış bağlamla beslenirse işe yaramıyor.